

第三单元 第三讲

高速缓冲存储器Cache

刘 卫 东 计算机科学与技术系

内容提要



- ◆Cache的地址映射
 - 全相联映射
 - 直接映射
 - ■多路组相联
- **⇔**Cache写策略
- ₩提高Cache性能的途径
 - 组织结构
 - Cache参数 (大小、块大小、替换策略)

层次存储器系统



- ◆使用高速缓冲存储器Cache来提高CPU对存储器的平均访问速度。
- ➡时间局部性: 最近被访问的信息很可能还要被 访问。
 - 图 将最近被访问的信息项装入到Cache中。
- *空间局部性: 最近被访问的信息临近的信息也可能被访问。
 - 平将最近被访问的信息项临近的信息一起装入到 Cache中。

高速缓冲存储器Cache



- ●基于程序的局部性原理
 - 时间局部性
 - 空间局部性
- ●利用静态存储器的高速特性
- ♥设置于主存储器与CPU之间
- ♥缓存CPU频繁访问的信息
- ♥提高CPU访问存储器的整体性能

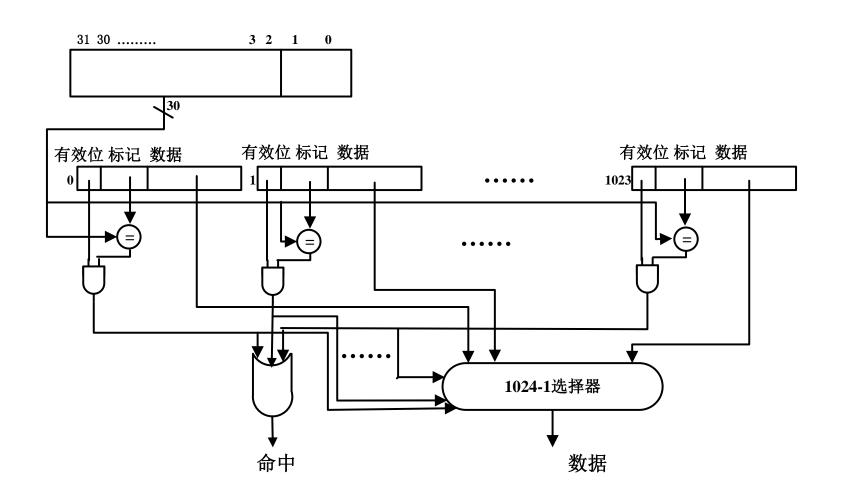
需要解决的问题



- ♥如何通过主存地址去访问Cache?
 - 全相联
 - ■直接映射
 - ■多路组相联
- ♥如何保证层次间一致性?
 - 有效位、写策略
- *Cache参数对性能的影响
 - Cache的组织: 块大小
 - 替换策略
 - ₩接入方式

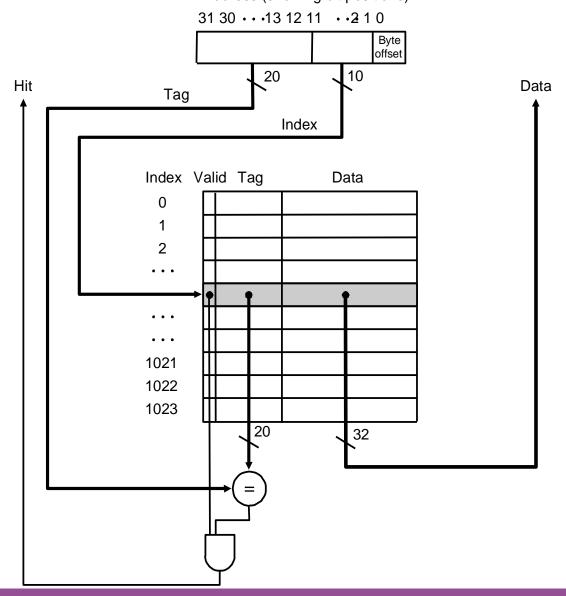
全相联映射硬件实现

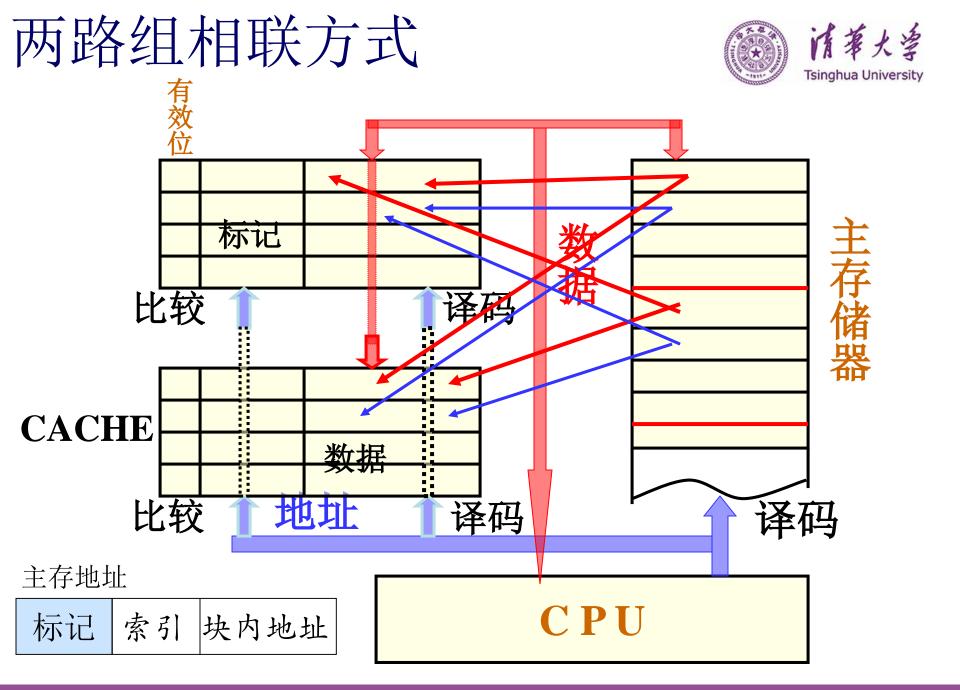




直接映射 Cache硬件实现







两路组相联方式



特点

- 1. 前两种方式的综合方案。先通过 直接映射方法确定组,再在组内通 过全相联方式确定行。
 - 2. 集中了两个方式的优点。成本也不太高。

是常用的方式

组相联Cache访问举例



假设有下列访问主存顺序:

Read location 0: Miss

□ Read location 16: Miss

□ Read location 32: Miss

Read location 4: Hit

Read location 8: Hit

Read location 36: Hit

□ Read location 32: Hit

Read location 128: Miss

Read location 148: Miss

□ Read location 0: Hit

□ Read location 128: Hit

□ Read location 4: Hit

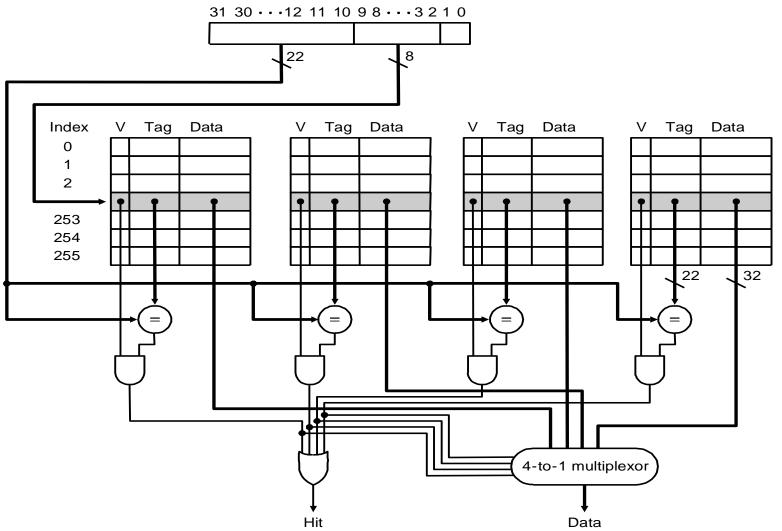
□ Read location 132: Hit

0-15 64-79

0-15	128-143
16-31	144-159
32-47	

四路组相联Cache实现





主存: 4GB, Cache: 4KB 块大小: 4B, 4路组相联, 索引? 标志?

直接映射到全相联



One-way set associative (direct mapped)

Block	Tag	Data
0		
1		
2		
3		
4		
5		
6		
7		

Two-way set associative

Set	Tag	Data	Tag	Data
0				
1				
2				
3				

Four-way set associative

Set	Tag	Data	Tag	Data	Tag	Data	Tag	Data
0								
1								

Eight-way set associative (fully associative)

Tag	Data														

一致性保证

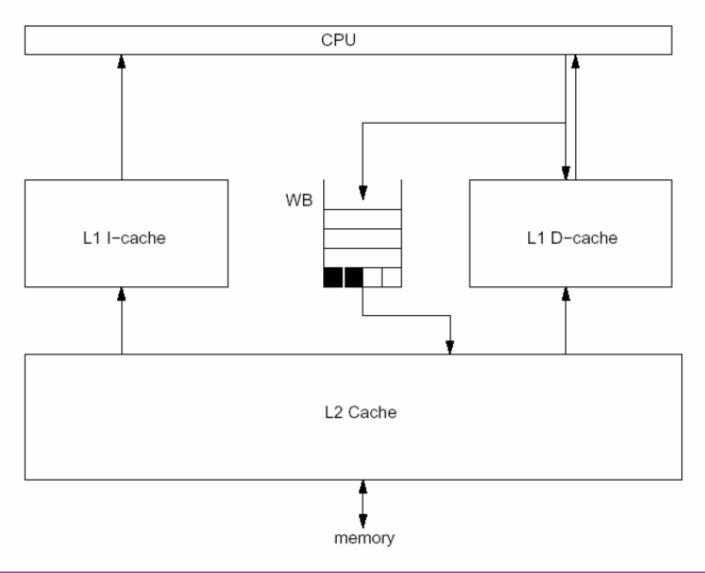


- ●写直达 (Write through)
 - ₩ 强一致性保证,效率低
 - ₩ 在Cache中命中
 - ◆同时修改Cache和对应的主存内容
 - ₩ 没有在Cache中命中
 - ◆写分配 (Write allocate)
 - ◆非写分配 (not Write allocate)
- 拖后写(Write back)
 - ₩ 弱一致性保证,替换时再写主存
 - ◆主动替换
 - ◈被动替换
 - ₩ 通过监听总线上的访问操作来实现
 - ₩ 实现复杂,效率比较高

Cache写(命中)



14



计算机科学与技术系 计算机组成原理

Cache (不命中) 写策略



		Write th	Write back				
	Write a	llocate	Write allocate				
Steps	fetch on miss	no fetch on miss			fetch on miss	no fetch on miss	
1	pick replacement	pick replacement			pick re- placement	pick re- placement	
2				invalidate tag	[write back]	[write back]	
3	fetch block				fetch block		
4	write cache	write partial cache			write cache	write partial cache	
5	write memory	write memory	write memory	write memory			

计算机科学与技术系 计算机组成原理

提高存储访问的性能



平均访问时间=

命中时间X命中率+缺失损失X缺失率

- ⇔提高命中率
- ⇔缩短缺失时的访问时间
- ♥提高Cache本身的速度

Cache缺失的四类原因



- ⇔必然缺失 (Compulsory Miss)
 - ₩ 开机或者是进程切换
 - 首次访问数据块
- ◆容量缺失 (Capacity Miss)
 - 活动数据集超出了Cache的大小
- ♥冲突缺失 (Conflict Miss)
 - 多个内存块映射到同一Cache块
 - **某一Cache组块已满,但空闲的Cache块在其他组
- ♥无效缺失
 - 其他进程修改了主存数据

对策

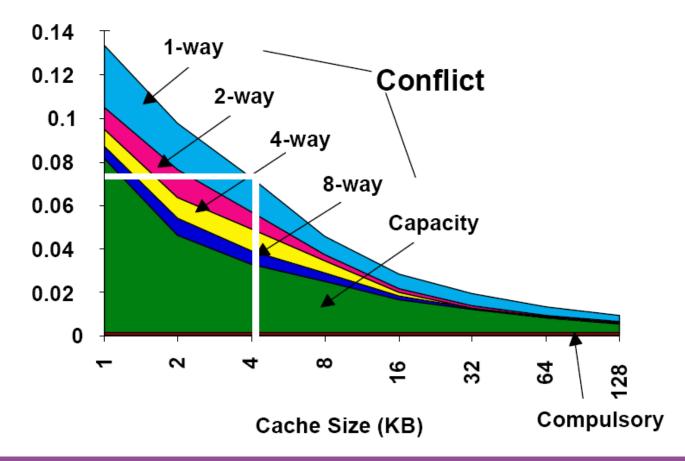


- * 必然缺失
 - 世事总有缺憾
 - ₩ 如果程序访问存储器的次数足够多,也就可以忽 略了
 - 策略
 - ◆预取
- * 容量缺失
 - 出现在Cache容量太小的时候
 - ₩ 增加Cache容量,可缓解缺失现象
- ⇔冲突缺失
 - 题 两块不同的内存块映射到相同的Cache块
 - ₩ 对直接映射的Cache, 这个问题尤其突出
 - ◆增加Cache容量有助于缓解冲突
 - ◆增加相联的组数有助于缓解冲突

影响Cache缺失率的因素



◆ 经验总结:容量为N、采用直接映射方式Cache的缺失率和容量为N/2、采用2路组相联映射方式Cache的缺失率相当



计算机科学与技术系 计算机组成原理

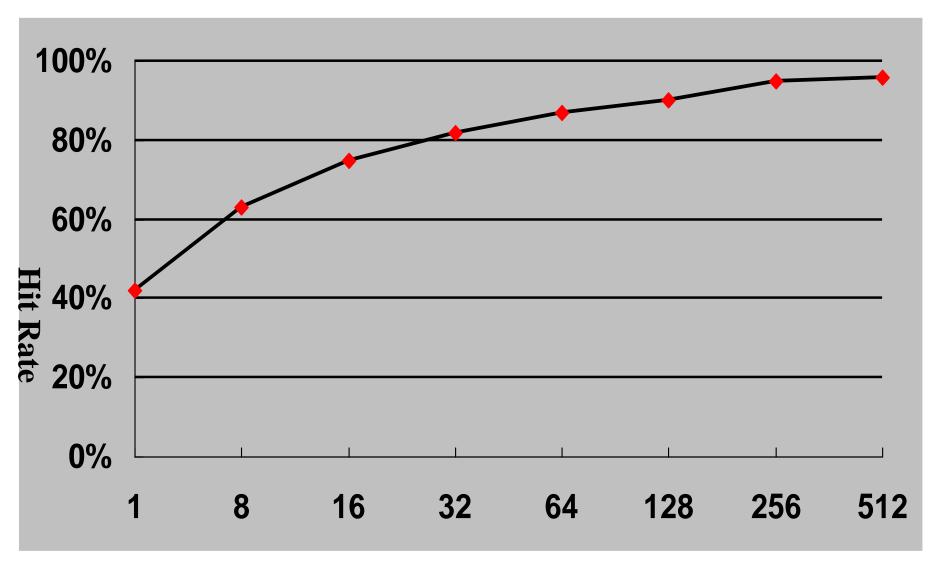
影响命中率的因素



- **⇔** Cache 容量
 - ☆大容量可以提高命中率,但是......
- ◆Cache块大小
 - ₩ 选择多大的行,还真是个问题
- ⇔地址映射方式
 - ■多路组相联,但到底多少路呢?
- ⇔替换算法
 - ₩ 替换哪行出去呢?
- ◆ 多级Cache
 - 給用户更多的选择

命中率与容量的关系

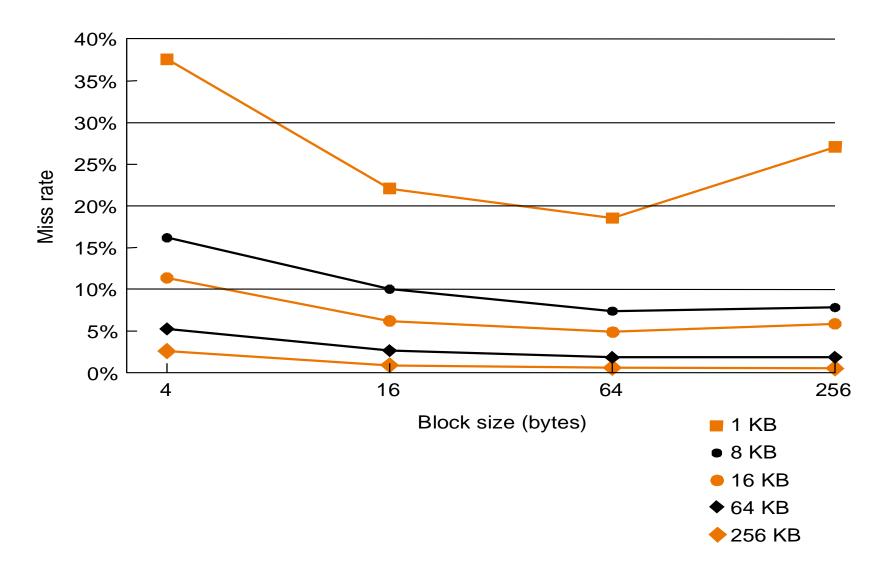




Cache Size in KB

块大小和缺失率的关系

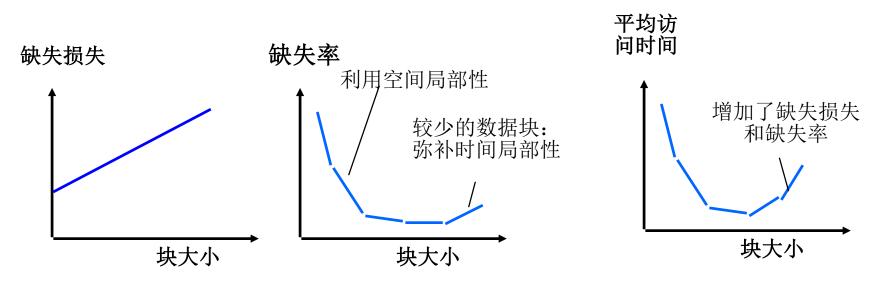




块大小的权衡



- ♥ 数据块较大可以更好地利用空间局部性
 - 数据块大意味着缺失损失的增大:
 - ◆需要花费更长的时间来装入数据块
 - ₩ 若块大小相对Cache总容量来说太大的话,命中率将降低
 - ◆Cache块数太少
- ◆ 平均访问时间=命中时间 x 命中率 + 失效损失 x 缺失率



块替换策略



- ♦ 直接映射
 - 主存中的一块只能映射到Cache中唯一的一个位置
 - ☎ 定位时,不需要选择,只需替换
- ♦ 全相联映射
 - 主存中的一块可以映射到Cache中任何一个位置
- ♥ N路组相联映射
 - 主存中的一块可以选择映射到Cache中N个位置
- ◆ 全相联映射和N路组相联映射的失效处理
 - ₩ 从主存中取出新块
 - ₩ 为了腾出Cache空间,需要替换出一个Cache块
 - ₩ 不唯一,则需要选择应替出哪块

替换策略



- ♥最近最少使用LRU
 - ₩ 满足程序局部性要求
 - 有较高命中率
 - ₩ 硬件实现复杂
- ◆先进先出FIFO
 - ₩ 满足时间局部性
 - ₩ 实现比较简单
- ♥随机替换RAND
 - ₩ 实现简单
 - 命中率也不太低

多级Cache



2.6

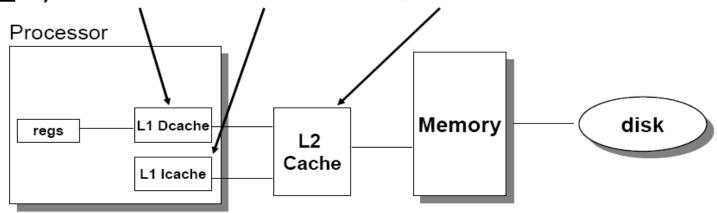
- ₩采用两级或更多级cache来提高命中率
 - ■增加Cache层次
 - ☆增加了用户的选择
- ⇔将Cache分解为指令Cache和数据Cache
 - 指令流水的现实要求
 - ■根据具体情况,选用不同的组织方式、容量

计算机科学与技术系 计算机组成原理

多级Cache



Options: separate data and instruction caches, or a unified cache



Inclusive vs. Exclusive

- ◆在处理器中设置独立的数据Cache和指令 Cache
- ◆在处理器外设置第二级Cache, 甚至是第 三级Cache

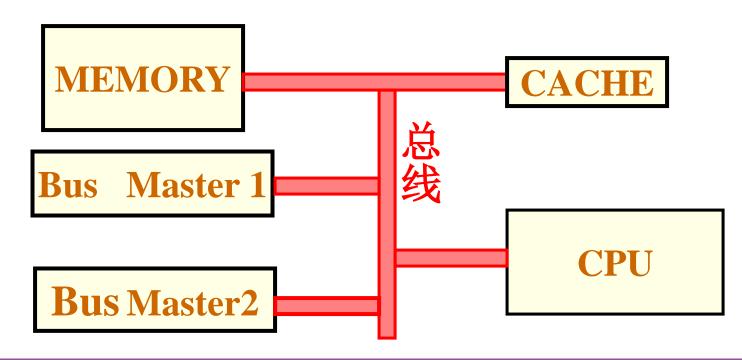
计算机科学与技术系 计算机组成原理

CACHE 接入系统的体系结构 ②



2.8

1. 侧接法:像入出设备似的连接到 总线上,优点是结构简单,成本低, 缺点是不利于降低总线占用率。



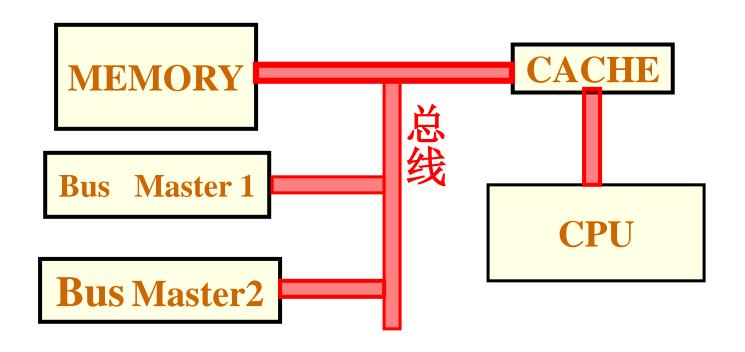
计算机科学与技术系 计算机组成原理

CACHE 接入系统的体系结构



29

2. 隔断法: 把原来的总线打断为两段, 使 CACHE 处在两段之间, 优点是有利于提 高总线利用率, 支持总线并发操作, 缺点 是结构复杂, 成本较高。



计算机科学与技术系 计算机组成原理

Pentium上的Cache



- ♥Intel的80386及更早的处理器芯片上并没有片上的高速缓冲存储器。
- ◆80486: 引入一个8KB的片上Cache, 其块大小为16B, 采用的是四路组相联映射方式。
- ◆Pentium: 芯片上已经有了两个8KB的片上 cache, 一个用作指令缓存, 另一个用作数据 缓存。它们的块大小都为32B, 采用两路组相 联的组织方式。

计算机科学与技术系

Pentium的数据缓存



- ◆数据缓存由128组,每组两个cache行组成,从逻辑上可以看成是大小为4KB的两"路"。
- ◆ 每个cache块都有20位的标记位和两位的状态位与 其对应,标记位即存放在该cache块中的主存块的 地址的高20位,两位状态位可以标记出4个不同的 块状态。
- ◆替换算法采用的是最近最少使用法(LRU),所以 对每组cache块还需要有1位的LRU位来表示CPU最 近访问的是该组中的哪一块。
- ◆ 采用拖后写策略。
- ◆ 支持两级Cache。

计算机科学与技术系

·致性保证策略(MESI)



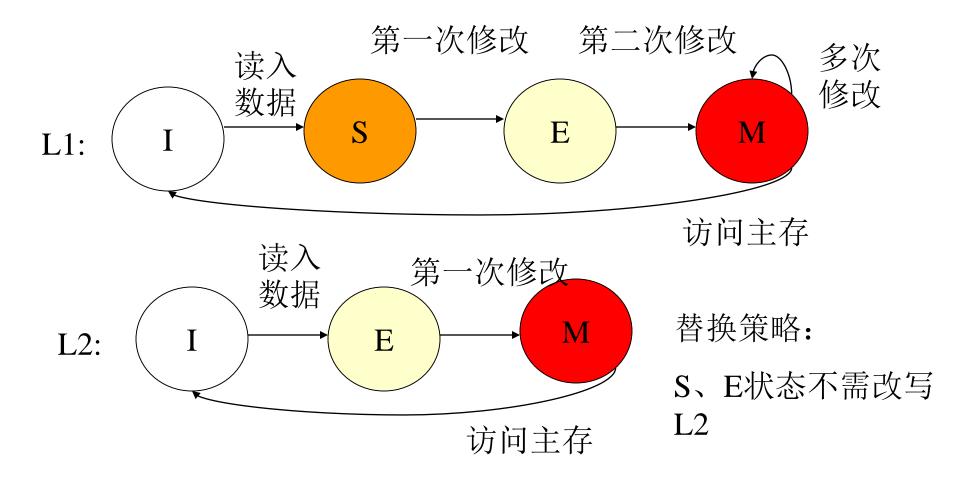
- ♦ 修改态 (M): 处于这个状态的cache块中的数 据已经被修改过,和主存中对应的数据已不同, 只能从cache中读到正确的数据。
- ♦ 独占态(E):处于本状态的cache块的数据和主 存中对应的数据块内容相同,而且在其它cache 中没有副本。
- ♦ 共享态(S):处于本状态的cache块的数据和主 存中对应的数据块内容相同, 而且可能在其它 cache中有该块的副本。
- ◆ 无效态(I): 处于本状态的cache块中尚未装入 数据。

计算机科学与技术系 计算机组成原理

32

两级Cache块的状态转换





写主存顺序



- ◆L2监听到其它总线主设备读请求,并要求该设备等待;
- ◆L2将要被写的地址传给L1,如果L1中的数据 在一次写之后有了新的修改(状态为M),则 需要将L1中该块的数据写回到主存中。任何情况下,都将该块的状态标记为非法态(I)。
- ◆如果L1中的数据与L2相同,则无须L1将数据写回主存中,而只要L2把自己的块的内容写回即可。但还是要把该块的状态标记为非法态(I)。
- ♥L2唤醒总线主设备,由它完成读操作。

Cache



- ♥目标
 - ₩提高CPU访问存储器系统的平均速度
- ♥策略
 - □利用一容量较小(降低成本)的高速缓冲存储器
- ♥组织方式
 - ☆ 全相联、直接映射、组相联

Cache



- ⇔包含性保证
 - cache中的块和主存中的块进行映射
- ⇔一致性保证
 - □写回主存策略
- ♥提高命中率
 - 容量
 - ₩关联方式
 - ₩块替换算法

Cache



- ♦ 局部性原理:
 - □ 任何时候,程序需要访问的只是相对较小的一些地址空间。
 - ◆时间局部性
 - ◆空间局部性
- ♦ 三类主要的Cache缺失原因:
 - ₩ 必然缺失:如:第一次装入
 - 中突缺失: 增大Cache容量、改进组织方式

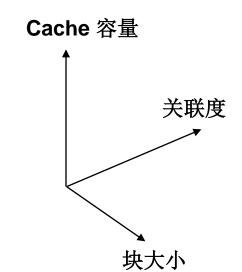
避免不断的块冲突

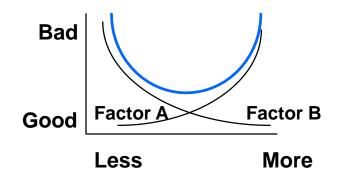
- ₩ 容量缺失: 增大Cache容量
- ♥ Cache设计
 - ₩ 总容量、块大小、组织方式
 - ₩ 替换算法
 - □ 写策略(命中时):写直达、拖后写
 - 写策略(不命中时):是否装入到Cache?

设计 Cache



- ♦ 有关方案
 - ™ cache 容量
 - ₩块大小
 - 组织方式
 - ₩ 替换算法
 - □写策略
- ♦ 方案优化
 - ₩ 根据用途选择
 - ◆海量数据处理
 - ◆指令数据平衡
 - ₩ 根据成本优化
- ♦ 简单化常常就是优化





阅读和思考



- *大实验检查验收安排
 - ₩ 时间: 周三~周五, 8:30~11:30 13:30~16:30
 - ₩ 地点:东主楼9-422
- ⇔阅读
 - 教材相关章节
 - □ 预习虚拟存储器
- ♥思考
 - Cache命中率和哪些因素有关?如何提高Cache的命中率?
 - ₩ Cache写有许多策略, 试进行比较。